

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ «ВЫСШАЯ ШКОЛА
ЭКОНОМИКИ»

Московский институт электроники и математики

Адодин Артём Андреевич, Быстров Сергей Сергеевич и Евтютова Анна Алексеевна

Влияние новостей на динамику акций NVIDIA

Руководитель проекта
Константинова Елизавета Павловна

Москва 2025г.

АННОТАЦИЯ

Данная работа посвящена исследованию зависимости цены акции от различных новостного контента, публикуемым в открытых источниках. Для работы с таблицами данных мы воспользовались библиотекой Pandas на базе языка программирования Python: в ней мы изучили основные структуры данных и функции для работы с ними. Это позволило эффективно работать с большими массивами информации, обеспечивая высокую точность вычислений. После выбора подходящих датасет, обработав их данные мы собрали новый датасет, содержащий информацию о дате выхода новости, цене акции на эту дату и выбрали слова, количество которых будем подсчитывать в тексте новостей. На конечном этапе получили значение корреляции от цены акции и рассматриваемого значения переменной, за счёт которого сформировали результат.

Содержание

1	Введение	3
1.1	Актуальность проблемы	3
1.2	Цель	3
1.3	Задачи	3
1.4	Литературный обзор	4
2	Описание данных	6
3	Методы	7
3.1	Поиск датасетов	7
3.2	Создание рабочего датасета	7
3.3	Выбор ключевых слов	8
3.4	Подсчет значения корреляции между двумя столбцами дан- ных	8
3.5	Формула Рамануджана	9
3.6	Результаты работы	10
4	Вывод	11
	Список литературы	12

1 Введение

В современном мире фондового рынка цена акций подвержена влиянию множества финансовых, экономических и политических факторов, и все эти факторы узнаются через новостное представление. В данной работе исследуется взаимосвязь между публикацией новостей, связанных с технологической и политической сферой, и изменением стоимости акций компании NVIDIA. Для анализа используются данные по ценам акций и соответствующий датасет новостей за тот же период. Основным методом исследования — корреляционный анализ, позволяющий выявить зависимость между появлением определённых ключевых слов в новостях и динамикой цен.

1.1 Актуальность проблемы

Понимание влияния новостного фона на котировки акций представляет значительный интерес для инвесторов и трейдеров, поскольку позволяет прогнозировать рыночные колебания и принимать более обоснованные решения, которые помогут сохранить или увеличить капитал владельца. NVIDIA, как одна из ведущих технологических компаний, активно освещается в СМИ, что делает её удобным объектом для подобного анализа. Исследование также может быть полезно для разработки автоматизированных систем торговли, учитывающих новостные сигналы.

1.2 Цель

Целью работы было выявление коэффициента корреляции между публикацией новостей, содержащих определённые ключевые слова, и с помощью этого коэффициента предсказывать изменение цены акций NVIDIA.

1.3 Задачи

Для достижения поставленной цели необходимо решить следующие задачи:

- Собрать данные по ценам акций NVIDIA.
- Найти и подготовить датасет новостей за аналогичный период, содержащий заголовки и тексты публикаций.
- Провести корреляционный анализ между появлением ключевых слов в новостях и изменением цены акций.

- Визуализировать результаты для наглядного представления выявленных зависимостей.
- Сделать выводы о значимости новостного фактора в изменении котировок.

1.4 Литературный обзор

Задача исследования влияния новостей на волатильность акций возникла из потребности финансовых аналитиков и трейдеров в прогнозировании рыночных колебаний. Как показано в разделе 1.1, понимание этой взаимосвязи позволяет принимать более обоснованные инвестиционные решения. Работы McKinney (2012, 2015) [1] [2] демонстрируют важность анализа данных для финансовых прогнозов.

В области анализа влияния новостей на фондовый рынок можно выделить несколько ключевых подходов:

- Корреляционный анализ [6] (как в нашем исследовании, см. раздел 1.3)
- Методы машинного обучения для обработки естественного языка [5]
- Анализ тональности текстов [7]

Преимуществом нашего подхода, описанного в разделе 1, является простота интерпретации результатов, однако он имеет ограничения в виде учета только частоты ключевых слов без анализа контекста.

Результаты нашего исследования, представленные в разделе 1.3, могут быть применены в различных новостях, таких как:

- Алгоритмической торговле [4]
- Риск-менеджменте [8]
- Финансовом консалтинге
- Разработке торговых роботов

Как показано в работе Бавриной и Борисова (2021) [3], методы корреляционного анализа находят широкое применение в различных областях, включая финансы.

Наше решение имеет следующие преимущества:

- Простота реализации (использование Pandas, как описано в аннотации)

- Наглядность результатов (см. таблицы 1 и 2)
- Быстрота вычислений

Однако существуют и недостатки:

- Ограниченный набор ключевых слов
- Не учитывается контекст употребления слов
- Корреляция не означает причинно-следственную связь

Дальнейшее развитие проекта, как указано в разделе 1, может устранить некоторые из этих ограничений.

2 Описание данных

Для выполнения задачи были использованы два датасет: первый содержит новости, вышедшие с 12 марта 2016 года по 31 декабря 2017 года (включительно), второй - цену акции в день закрытия биржи и дату этого дня с 1 января 1999 года по 12 апреля 2014 года (включительно). Данные были обработаны и объединены в один датасет (файл `dataset.csv`) со следующими колонками:

1. Date: дата.
2. Price: цена акции на эту дату.
3. News: текст новости, которая вышла в эту дату.
4. War: количество повторений слова "War" с учетом регистра в тексте соответствующей новости.
5. Stock: количество повторений слова "War" с учетом регистра в тексте соответствующей новости.
6. Terror: количество повторений слова "Terror" с учетом регистра в тексте соответствующей новости.
7. Trump: количество повторений слова "Trump" с учетом регистра в тексте соответствующей новости.

3 Методы

3.1 Поиск датасетов

Первым шагом нашей работы является поиск датасета с ценой акцией в определенные дни и поиском датасета, где будут столбцы с текстом новости и датой выхода этой новости. С этой задачей мы справились с помощью сайта Kaggle, где мы и скачали датасеты, доступные для каждого пользователя.

3.2 Созданием рабочего датасета

Дальше мы занялись объединением двух датасетов в один единый. Для этого нам понадобилась библиотека pandas, поэтому первым делом мы подключили её (см. Рис. 1).

```
1  import pandas as pd
2  from datetime import datetime
3
4  def date_num(str):
5      date_object = datetime.strptime(str.strip(), "%B %d, %Y")
6      formatted_date = date_object.strftime("%Y-%m-%d")
7      return formatted_date
8  def str_srav(str1, str2):
9      sum = 0
10     for x in range(5, 10):
11         if str1[x] != str2[x]: sum += 1
12     if sum == 0: return 1
13     else: return 0
14
15  df = pd.read_csv('True.csv')
16  rop = df[['text', 'subject']]
17  rop.insert(2, 'date', '')
18  for x in rop.index:
19      rop.loc[x, 'date'] = date_num(df.loc[x, 'date'])
20  lk = rop[((rop['date'].str[2] == '1') & (rop['date'].str[3] == '7') & (rop['subject'] == "worldnews"))]
21  lk.index = range(len(lk))
22
23
24  act = pd.read_csv('NVDA_1999-01-01_2024-12-04.csv')
25  k1 = act[['Date', 'Close']]
26  new_act = k1[((k1['Date'].str[2] == '1') & (k1['Date'].str[3] == '7'))]
27  new_act.index = range(len(new_act))
28
29
30  new_act.insert(2, 'News', '')
31
32  for x in new_act.index:
33      for y in lk.index:
34          if str_srav(new_act.loc[x, 'Date'], lk.loc[y, 'date']):
35              new_act.loc[x, 'News'] = lk.loc[y, 'text']
36              break
37
38
39  new_act.to_csv('end_dataset.csv', index=False)
```

Рис. 1: Код объединения двух датасетов

Прочитав из файла True.csv данные таблицы в переменную df, мы начали обрезать ненужные данные. В переменную rop (структуры DataFrame)

изначально записали столбец с текстом акции - 'text', затем с помощью функции `datenum()` добавили столбец 'date', который теперь содержал данные о дне в цифровом виде: 2017-12-23, а не в виде представленном в файле True.csv: December 23, 2017. Далее в переменную `lk` мы сохранили только те строки, в которых статья новости вышла в 2017 году. Так мы подготовили 1 часть будущего датасета.

В переменную `ast` прочитали файл 'NVDA1999-01-012024-12-04.csv', затем обрезав не нужные столбцы, хранившиеся в файле, мы в переменную `kl` записали столбцы 'Date' - дата и 'Close' - цена акции. И в конце в переменную `newast` добавили строки с датой в диапазоне с 01.01.2017 до 31.12.2017. Данный код можно увидеть в 24-27 строках на Рис.1.

Добавив в переменную `newast` новый столбец 'News', мы начали заполнять его. Если дата со столбца 'Date' переменной `newast` равно дате со столбца 'date' переменной `lk`, то в столбец 'News' записываем текст новости из столбца 'text'. Таким образом в переменной `newast` появилось 3 столбца: 'Date' - дата, 'Close' - цена акции в этот день, 'News' - текст новости, вышедшей в этот день.

3.3 Выбор ключевых слов

Выбрав ключевые слова, мы добавили столбцы в датасет с названиями этих переменных. Значения этих столбцов, отвечают за частоту повторения данного слова в тексте новости. Пример такой таблицы представлен в (Таблица 1)

Таблица 1: Часть итогового датасета (файл dataset.csv)

Data	Price	News	Stock	War	Terror	Trump
2017-05-24	3.464250087738037	BRUSSELS (Reuters)...	3.0	0	2	20
2017-05-25	3.4565000534057617	BOZEMAN, Mont. (Reuters)...	3.0	0	0	7
2017-05-26	3.5460000038146973	WASHINGTON(Reuters)...	2.0	0	0	0
2017-05-30	3.6217501163482666	WASHINGTON(Reuters)...	0.0	0	0	12
2017-05-31	3.608750104904175	WASHINGTON(Reuters)...	8.0	0	0	18

3.4 Подсчет значения корреляции между двумя столбцами данных

После изучения полученного датасета в переменную `df` мы записали данные файла dataset.csv и получили результаты (Таблица 2).

Таблица 2: Значение коэффициента корреляции

Данные 1ого элемента	Данные 2ого элемента	Вывод
Close	War	0.01642240473281341
Close	Stock	-0.08193588804691303
Close	Terror	0.04505825945436033
Close	Trump	-0.3589977477045141

]Воспользовались функцией `corr`, встроенной в программную библиотеку для обработки и анализа данных - Pandas, благодаря чему смогли подсчитать значение корреляции (Рис. 2). Коэффициент корреляции находится в диапазоне от -1 до 1. Значение 1 означает идеальную положительную корреляцию, -1 — идеальную отрицательную, 0 — отсутствие корреляции.

```

1  import pandas as pd
2
3  df = pd.read_csv('dataset.csv')
4  print(df['Close'].corr(df['War']))
5  print(df['Close'].corr(df['Stock']))
6  print(df['Close'].corr(df['Terror']))
7  print(df['Close'].corr(df['Trump']))
8

```

Рис. 2: Подсчет корреляции

3.5 Формула Рамануджана

$$\frac{1}{\pi} = \frac{2\sqrt{2}}{9801} \sum_{k=0}^{\infty} \frac{(4k)!(1103 + 26390k)}{(k!)^4 396^{4k}} \quad (1)$$

Формула 1, открытая индийским математиком Сринивасой Рамануджаном, позволяет вычислять значение

$$\frac{1}{\pi}$$

с высокой точностью. Её особенность заключается в быстрой сходимости: каждый новый член ряда добавляет примерно 8 десятичных знаков точности. Формула демонстрирует глубокую связь между комбинаторикой, теорией чисел и анализом, а её доказательство основано на методах модулярных форм. Сегодня подобные алгоритмы используются для рекордных вычислений числа π

3.6 Результаты работы

По данным Таблице 2 можно сказать, что корреляция между ценой акций и ключевыми словами 'war', 'stock', 'terror' не прослеживается. А между ключевым словом 'Trump' и ценой акцией можно заметить небольшую обратную корреляцию. То есть, чем чаще фамилия президента США встречается в тексте новостей, тем ниже становится цена акций Nvidia.

4 Вывод

Наш проект, посвященный прогнозированию движения акций на основе анализа новостной ленты, представляет собой исследование, направленное на выявление влияния новостей на цены акций. Мы исходили из соображения, что ключевые слова, отражающие важные события и настроения, могут быть использованы для предсказания краткосрочных изменений цены акций. Однако мы обнаружили, что не все слова, даже те, которые интуитивно кажутся важными для инвесторов и часто обсуждаются в финансовом сообществе, обладают выраженной корреляционной зависимостью с движением цены акций. Более того, даже в случаях, когда корреляция наблюдалась, ее коэффициент зачастую был невысок. Данный факт объясняется тем, что цена акции формируется под воздействием множества факторов, и новостная лента является лишь одним из этих факторов. Уменьшение цены акции, например, может быть вызвано не негативными новостями, а, скажем, общей коррекцией рынка или публикацией слабой финансовой отчетности компании. Несмотря на это, наши результаты не следует рассматривать как неудачу. Наоборот, они представляют собой ценные первичные признаки, указывающие на потенциальную связь между новостной информацией и поведением акции. Мы считаем, что дальнейшее углубление в мир финансовой аналитики, можно будет делать более точные расчеты.

Список литературы

1. *McKinney W.* Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython. — Sebastopol, CA : O'Reilly Media, 2012. — ISBN 978-1-449-31979-3. — (дата обращения: 20.05.2025).
2. *McKinney W., Team P. D.* Pandas: Powerful Python Data Analysis Toolkit. — 2015. — (дата обращения: 20.05.2025).
3. *Баврина А. П., Борисов И. Б.* Современные правила применения корреляционного анализа // Медицинский альманах. — 2021. — 3(68). — С. 70—79. — (дата обращения: 20.05.2025).
4. *Володин С. Н., Якубов А. П.* Влияние алгоритмической торговли на устойчивость развития мировых фондовых рынков // Финансы и кредит. — 2017. — Т. 23, 20 (740). — С. 1184—1195. — (дата обращения: 20.05.2025).
5. *Качнов С. А.* Методы машинного обучения для обработки естественного языка // Наука молодых - будущее России. — 2020. — С. 41—44. — (дата обращения: 20.05.2025).
6. *Конюхова Г. П., Бритвина В. В., Конюхов В. Г.* Методы корреляционного анализа. — 2012. — (дата обращения: 20.05.2025).
7. *Котельников Е. В., Клековкина М. В.* Автоматический анализ тональности текстов на основе методов машинного обучения // Компьютерная лингвистика и интеллектуальные технологии. — 2012. — Т. 2, № 11. — С. 27. — (дата обращения: 20.05.2025).
8. *Чекулаев М. В.* Риск-менеджмент: управление финансовыми рисками на основе анализа волатильности. — М. : Михаил Чекулаев, 2002. — (дата обращения: 20.05.2025).